

Nienadzorowana Detekcja Anomalii oraz Analiza Sprawiedliwości Algorytmicznej w Wykrywaniu Oszustw Bankowych

STRESZCZENIE

W praktyce sektora finansowego identyfikacja wniosków o otwarcie konta stanowiących oszustwo charakteryzuje się opóźnioną w czasie, kosztowną oraz obciążoną błędem selekcji próby etykietyzacją klas. Klasyczne modele uczenia nadzorowanego dziedziczą obciążenia historycznych decyzji oraz wykazują ograniczoną elastyczność w detekcji nowych wzorców przestępczych. W niniejszej pracy przeprowadzono systematyczne badanie porównawcze sześciu algorytmów nienadzorowanej detekcji anomalii oraz autorskiego modelu zespołowego (*ensemble*) na benchmarkowym zbiorze danych *Bank Account Fraud (BAF)* NeurIPS 2022 ($N = 1\,000\,000$). Analiza obejmuje zagadnienia efektywności predykcyjnej, podatności modeli na dryf koncepcyjny, ewaluację sprawiedliwości algorytmicznej (*fairness*) w kontekście obciążenia wiekowego (*age bias*) oraz ocenę zgodności z wymogami regulacyjnymi (RODO, EU AI Act).

1. Wprowadzenie i Cel Badania

Procedury weryfikacji tożsamości oraz oceny ryzyka przy otwieraniu rachunków bankowych stanowią fundamentalny element ochrony instytucji finansowych przed stratami wywołanymi przestępczością tożsamościową. Stosowanie klasycznych algorytmów uczenia nadzorowanego w systemach produkcyjnych ograniczone jest trzema kluczowymi zjawiskami:

- Opóźnienie etykiety klasowej (Label Delay):** Potwierdzenie faktu popełnienia oszustwa następuje zazwyczaj ze znacznym opóźnieniem czasowym (od kilku tygodni do kilku miesięcy).
- Sample Selection Bias:** Etykiety wskazujące na fraud są znane wyłącznie przez wnioski zaakceptowane przez dotychczasowe systemy decyzyjne.
- Concept Drift:** Przestępcy stale modyfikują wzorce działań w czasie.

Cel niniejszej pracy stanowi ewaluacja użyteczności wybranych modeli nienadzorowanych jako wstępnego kroku w procesie filtrowania podejrzanych transakcji w danych bankowych.

2. Metodologia i Przygotowanie Danych

2.1. Zbiór Danych BAF (NeurIPS 2022)

Ewaluację przeprowadzono na oficjalnym zbiorze danych *Bank Account Fraud (BAF)* zaprezentowanym podczas konferencji NeurIPS 2022. Zbiór obejmuje 1 000 000 wniosków o otwarcie konta bankowego. Odsetek klasowo zrównoważonych oszustw (zmienna `fraud_bool`) wynosi $\sim 1,1\%$.

2.2. Temporalny Podział Czasowy (Out-of-Sample Split)

W celu zapobiegania zjawisku wycieku informacji z przyszłości (data leakage) oraz odzwierciedlenia realnych warunków wdrożenia produkcyjnego, dane podzielono według kryterium czasowego (`month`):

- Zbiór Treningowy (Train):** Miesiące 0 – 5 (dane historyczne, N = 600 000 obserwacji).
- Zbiór Testowy (Test OOS):** Miesiące 6 – 7 (przyszłe obserwacje, N = 400 000 obserwacji).

Wykluczono całkowicie zmienną `device\_fraud\_count`, stanowiącą agregację wyników z wcześniejszych procedur sprawdzających (zjawisko *near-label leakage*).

2.3. Transformacje Preprocessingowe (Receptura A2)

Zaprojektowano i przetestowano dedykowany schemat transformacji zmiennych wejściowych:

1. Kodowanie Braków Danych (MNAR): Brak danych w zmiennej `prev\_address\_months\_count` występował w 92,2% wniosków oszukańczych wobec 71,3% w populacji ogólnej. Zamiast imputacji wartością środkową, wygenerowano binarne flagi obecności braku (`na\_flag\_\*`), przekształcając brak danych w silny sygnał predykcyjny.
2. Frequency Encoding: Zmienne kategoryczne o wysokiej kardynalności (`device\_os`, `housing\_status`) zakodowano częstością ich występowania na zbiorze treningowym.
3. Zmienne Relacyjne: Utworzono cechy złożone mierzące proporcje ryzyka do dochodu (`risk\_to\_income`), stabilności zamieszkania do wieku (`address\_stability`) oraz wnioskowanego limitu do dochodu (`loan\_to\_income`).
4. Selekcja Wymiarowości (Receptura A2): Rezygnacja z nieliniowych przekształceń Yeo-Johnsona na rzecz wyselekcjonowanego podzbioru 8 zmiennych cechujących się najwyższą stabilnością macierzy kowariancji.

3. Ewaluowane Metody Nienadzorowane

W badaniu poddano analizie 6 zróżnicowanych algorytmów oraz model hybrydowy:

1. Odległość Mahalanobisa: Parametryczna metoda mierząca odległość punktu od wielowymiarowego środka ciężkości rozkładu z uwzględnieniem macierzy kowariancji cech (z regularyzacją Ridge).
2. Isolation Forest: Zespół drzew losowych, w którym miarą anomalii jest średnia długość ścieżki potrzebna do odizolowania danej obserwacji.
3. Local Outlier Factor (LOF): Nieparametryczny algorytm gęstościowy wyznaczający lokalną względną rzadkość otoczenia punktu w oparciu o k -najbliższych sąsiadów.
4. Głęboki Autoenkoder (H2O Deep Learning): Architektura sieci neuronowej redukująca i rekonstruuująca sygnał; miarą anomalii jest błąd średniokwadratowy rekonstrukcji (MSE).
5. K-Means Clustering: Algorytm grupowania (dla $k=3$), gdzie miarą anomalii jest odległość euklidesowa od najbliższego centroidu.
6. One-Class SVM (OCSVM): Jądrowa metoda wyznaczania optymalnej hiperpowierzchni ograniczającej rozkład populacji wzorcowej z jądrem RBF ($\nu=0,011$).
7. Model Zespołowy (Ensemble Pipeline): Ważona agregacja znormalizowanych rang ocen generowanych przez Isolation Forest, Autoenkoder oraz OCSVM.

4. Wyniki Empiryczne i Dyskusja

Tabela 1. Efektywność predykcyjna badanych modeli nienadzorowanych na zbiorze testowym Out-of-Sample (Miesiące 6–7)

Model / Algorytm	AUC-ROC	Recall @ 1%	Recall @ 5%	Recall @ 10%	Lift @ 1%	Lift @ 10%
Mahalanobis (Receptura A2)*	0,653	0,019	0,097	0,171	1,9×	1,71×
Autoenkoder Głęboki (H2O)	0,630	0,025	0,089	0,166	2,5×	1,66×
Isolation Forest	0,613	0,022	0,097	0,173	2,2×	1,73×
One-Class SVM (RBF)	0,583	0,015	0,098	0,173	1,5×	1,73×
LOF (bez cechy wieku)*	0,581	0,027	0,106	0,181	2,7×	1,81×
K-Means ($k=3$)	0,543	0,007	0,093	0,162	0,7×	1,62×
Model Zespołowy (Ensemble)	0,625	0,028	0,099	0,183	2,8×	1,83×

Kluczowe Wnioski z Ewaluacji Empirycznej:

- Modele nienadzorowane osiągają wartości AUC-ROC w granicach 0,54–0,65, co czyni je nieodpowiednimi jako samodzielne systemy decyzyjne (w porównaniu do modeli nadzorowanych osiągających AUC 0,82–0,88). Zapewniają one jednak wysoki współczynnik podbicia Lift@1% w przedziale 1,9× – 2,8×, co pozycjonuje je jako doskonałe narzędzia wstępnej filtracji i priorytetyzacji obciążenia analityków.
- Ograniczenie liczby cech do 8 najistotniejszych wymiarów zwiększyło wskaźnik AUC Odległości Mahalanobisa z 0,564 do 0,653 (+8,9 p.p.), przesuując tę klasyczną metodę na pozycję lidera pojedynczych estymatorów.
- Model zespołowy zoptymalizował stabilność wskaźników detekcji w najwyższym decylnym ryzyku, osiągając najwyższy współczynnik Recall@1% (2,8%) oraz Lift@1% (2,8×).

5. Analiza Zaawansowana

5.1. Sprawiedliwość Algorytmiczna i Dyskryminacja Wiekowa

Przeprowadzona analiza odsetka fałszywych alarmów (FPR) w poszczególnych podgrupach wiekowych wykazała występowanie znacznego age bias:

- Wnioskodawcy z grupy <30 lat generowali najwięcej bezwzględnych oszustw ($n=1045$), przy czym modele dystansowe uzyskiwały dla nich niski wskaźnik detekcji (Recall@5% = 6,9%–8,0%).
- Wnioskodawcy z grupy 60+ przy niewielkim udziale w przestępczości ($n=68$) uzyskiwali drastycznie zawyżony współczynnik wykrywalności (Recall@5% = 19,1%–21,4%).

W przypadku algorytmu LOF obecność zmiennej `customer\_age` powodowała, że dla klientów w wieku 80+ wskaźnik fałszywych alarmów wynosił FPR = 1,00 (100%). Metody dystansowe traktują wiek podeszły jako rzadkość statystyczną, a nie rzeczywisty wskaźnik ryzyka. Usunięcie zmiennej wieku z przestrzeni wejściowej LOF pozwoliło na wyeliminowanie skrzywienia demograficznego bez utraty zdolności predykcyjnej.

5.2. Analiza Dryfu Koncepcyjnego (Concept Drift)

W celu oceny stabilności rozkładu zmiennych w czasie skonstruowano klasyfikator przeciwniczy (*Adversarial Discriminator* bazujący na modelu XGBoost) trenowany na zadaniu rozróżniania próbek pochodzących z miesięcy 0–5 od miesięcy 6–7.

Uzyskany wynik AUC-ROC równy 0,9986 potwierdził obecność niemal całkowitego przesunięcia rozkładu danych w czasie. Analiza ważności zmiennych wykazała, że głównym nośnikiem dryfu były skumulowane zmienne dynamiczne z grupy `velocity\_\*` (np. `velocity\_4w`). Usunięcie cech typu *velocity* zwiększyło stabilność czasową algorytmu Isolation Forest, podnosząc wskaźnik AUC na zbiorze testowym o +0,0016.

5.3. Profilowanie Archetypów Oszustw (Segmentacja K-Means)

Zastosowanie algorytmu klastrowania K-Means na próbie potwierdzonych oszustw pozwoliło na wyodrębnienie 3 głównych profili operacyjnych:

- Archetyp I (59,0% przestępstw): Klienci w średnim wieku o umiarkowanym wskaźniku ryzyka i ugruntowanej historii. Wzorzec odpowiadający kradzieży tożsamości (*Identity Theft*).
- Archetyp II (33,4% przestępstw): Młodzi wnioskodawcy o niskim dochodzie i braku historii. Wzorzec charakterystyczny dla słupów finansowych oraz zautomatyzowanych botów (*Money Mules / Botnets*).
- Archetyp III (7,6% przestępstw): Wnioski o wysokim deklarowanym dochodzie i niskim wskaźniku ryzyka. Wzorzec właściwy dla oszustw syntetycznych oraz wyludzeń limitów (*Bust-out Fraud*).

6. Aspekty Regulacyjne (RODO i EU AI Act)

Zastosowanie nienadzorowanych modeli detekcji anomalii w sektorze bankowym podlega ścisłym regulacjom prawnym:

1. Art. 22 RODO (GDPR): Zakazuje wydawania w pełni zautomatyzowanych decyzji wywołujących skutki prawne lub w podobny sposób istotnie wpływających na osobę. Z uwagi na umiarkowany poziom precyzji, modele nienadzorowane muszą działać wyłącznie w trybie nadzorowanym (*Human-in-the-loop*), wspierając priorytetyzację zadań dla analityków.
2. Akt w sprawie AI (EU AI Act 2024): Systemy klasyfikacji ryzyka oraz detekcji oszustw finansowych zaliczane są do kategorii systemów wysokiego ryzyka (*High-Risk AI Systems*). Wymagają one ciągłego audytu pod kątem braku dyskryminacji pośredniej (np. wiekowej), monitorowania dryfu danych oraz zapewnienia wytycznych interpretowalności.

7. Podsumowanie

Przeprowadzone badania wskazują, że metody nienadzorowanego uczenia maszynowego stanowią skuteczne wsparcie operacyjne w wykrywaniu oszustw bankowych, generując do 2,8-krotnego podbicia wykrywalności (*Lift@1%*) w stosunku do losowej inspekcji. Kluczowym czynnikiem sukcesu wdrożeniowego okazuje się odpowiednia inżynieria cech (kodowanie braków danych MNAR) oraz dbałość o sprawiedliwość algorytmiczną i czasową stabilność modeli w warunkach zmieniających się wzorców przestępczości.